Balancing and Interpretability in Credit Risk

Anonymous manuscript for blind review

JEL Classification: C45; C53; G21; G32; O33; M15.

Figure and Table Legends

Figure 1. Experimental workflow for the evaluation of balancing, prediction and local explanations.

Figure 2. Stability metrics for SHAP and LIME in German Credit Risk. Solid lines denote XGBoost and dashed lines denote Random Forest.

Figure 3. Predictive performance metrics for German Credit Risk. Solid lines denote XGBoost and dashed lines denote Random Forest.

Figure 4. Stability metrics for SHAP and LIME in HMEQ. Solid lines denote XGBoost and dashed lines denote Random Forest.

Figure 5. Predictive performance metrics for HMEQ. Solid lines denote XGBoost and dashed lines denote Random Forest.

Abstract

Class imbalance is a structural feature of credit risk because default cases are typically much less frequent than non-default cases. This study evaluates whether random balancing techniques alter the stability of local explanations in credit scoring models. The experimental design combines two credit datasets, German Credit Risk and Home Equity (HMEQ), two black-box classifiers, XGBoost and Random Forest, and two explanation methods, SHAP and LIME. Explanatory stability is assessed using the *Sequential Rank Agreement* (SRA) and the coefficient of variation (CV), while predictive performance is monitored through AUC and F1-Score. The results show that balancing is not interpretively neutral. Random under-sampling (RUS) produces the largest deterioration in explanatory stability, whereas random over-sampling (ROS) remains closer to the unbalanced baseline. Shapiro-Wilk, Friedman and post-hoc Nemenyi procedures provide additional statistical support for differences across balancing scenarios. Overall, model validation in credit risk should jointly consider predictive performance, resampling design and interpretive consistency.

Keywords

credit scoring; class imbalance; explainable machine learning; SHAP and LIME; random resampling; robustness analysis.

Key Messages

- Random balancing is not interpretively neutral.
- RUS produces the largest loss of explanatory stability.
- ROS preserves explanations closer to the unbalanced baseline.
- Robustness is tested with two datasets and two models.

Title

Balancing and Interpretability in Credit Risk

1. Introducción

El uso de modelos de Machine Learning (ML) en el sector financiero, especialmente en bancos centrales y entidades bancarias para automatizar y optimizar la toma de decisiones crediticias se ha incrementado significativamente (Araujo et al., 2023). Una de las razones es que los modelos de ML muestran una capacidad predictiva superior a los algoritmos tradicionales (Suhadolnik et al., 2023). Sin embargo en servicios financieros regulados los modelos de machine learning no son auditables por su comportamiento de caja negra, es decir, que las razones subyacentes por las que el modelo dio un resultado no se conocen, de modo que se requiere el uso de modelos explicativos que mitiguen este problema (Bussmann et al., 2021). Lo anterior no es algo de importancia nimia pues, como menciona Sanmartín González (2023), la interpretabilidad de los modelos de ML es de suma importancia para promover la transparencia y también, a nivel técnico, para tener la capacidad de comprender y explicar las predicciones de dichos modelos.

Existe un debate en la literatura sobre el intercambio que supone usar un modelo de machine learning con gran capacidad predictiva, pero con una menor explicabilidad (Chen et al., 2024), dicho conflicto se ve agravado por una característica inherente de los datos crediticios: el desbalance de clases (CI) que ocurre cuando una clase, comúnmente deudores, es en proporción ampliamente menor a la otra, no deudores) lo que sesga a los modelos hacia la predicción de la clase mayoritaria y reduce drásticamente su capacidad para detectar el riesgo real.

La viabilidad de la investigación se sustenta en el uso de modelos de ML, métodos de interpretabilidad y técnicas de balanceo implementadas en Python, aplicadas a dos bases de riesgo crediticio: *German Credit Risk*, disponible en Kaggle (Kaggle UCI ML Repository), y *Home Equity* (HMEQ). German Credit funciona como base principal del experimento, mientras que HMEQ permite evaluar la robustez externa de los resultados bajo una fuente de datos alternativa.

La utilidad de esta investigación radica en determinar si las técnicas de balanceo, aun cuando mejoran el desempeño predictivo, deterioran la consistencia de las explicaciones locales. Responder a esta cuestión puede ayudar a las entidades financieras a diseñar estrategias en las que los modelos no solo sean precisos, sino también robustos, transparentes y compatibles con exigencias regulatorias, condiciones fundamentales para una IA confiable en la gestión del riesgo.

En la práctica las bases de datos usadas para entrenar los modelos ML exhiben una proporción de clientes en situación de incumplimiento extremadamente baja, frecuentemente por debajo del 10 % e incluso del 5 % (Chen et al., 2024), este fenómeno de Class Imbalance (CI) obliga al uso de técnicas de balanceo para mejorar la capacidad predictiva de los modelos de ML.

Estas técnicas se agrupan en tres familias principales: el submuestreo, el sobremuestreo sintético como SMOTE y ADASYN y los métodos híbridos, como SMOTE-ENN (Alam et al., 2020). En esta investigación, sin embargo, las técnicas sintéticas e híbridas se mantienen fuera del alcance empírico. La ejecución experimental se delimita de manera estricta a *Random Under-Sampling* (RUS) y *Random Over-Sampling* (ROS), evaluadas sobre XGBoost y Random Forest. Esta delimitación responde a un criterio de parsimonia experimental: el uso de métodos aleatorios simples permite aislar el efecto puro de la redistribución de clases sobre la estabilidad de SHAP y LIME, evitando el ruido multiplicativo que la generación de observaciones sintéticas podría introducir en la evaluación de SRA y CV.

La literatura también ha documentado que las técnicas de balanceo pueden mejorar de forma sustancial métricas predictivas co-

mo AUC, precisión y *recall*, aunque a costa de distorsiones como la sobreestimación de positivos en ciertos contextos (Welvaars et al., 2023). Si bien ese hallazgo se refiere al plano predictivo, resulta razonable esperar que también tenga implicancias sobre la interpretabilidad. Para enfrentar el problema de la opacidad, la comunidad de *machine learning* ha desarrollado herramientas de explicabilidad post-hoc y agnósticas al modelo, como LIME (Local Interpretable Model-agnostic Explanations) y SHAP (SHapley Additive exPlanations). Estas técnicas funcionan como una capa de interpretación sobre el modelo de caja negra, asignando un valor de contribución a cada variable para explicar por qué se tomó una decisión específica para un cliente particular (Molnar, 2019).

El problema de esta investigación se sitúa precisamente en la intersección de estas dos prácticas. Diversos estudios, como el de Zhao et al. (2024), evalúan técnicas de balanceo aplicadas a distintos clasificadores y a conjuntos de datos con diferentes niveles de desbalance en términos de capacidad predictiva; sin embargo, todavía es escasa la evidencia sobre el efecto de esas técnicas en la estabilidad de los métodos de interpretabilidad. Ese vacío constituye el núcleo del aporte empírico de este trabajo.

En consecuencia, una práctica común y aceptada para mejorar la precisión predictiva el uso de técnicas de balanceo (Alarab & Prakoonwit, 2022) podría estar comprometiendo la fiabilidad de las explicaciones del modelo. Para las instituciones financieras, esto representa un riesgo de cumplimiento normativo y de gobernanza, pues obliga a verificar si la estabilidad de las explicaciones generadas por métodos de IA explicable se preserva o se deteriora cuando se interviene la distribución de clases.

2. Revisión bibliográfica

La literatura reciente en riesgo crediticio muestra una tensión persistente entre desempeño predictivo e interpretabilidad. Los modelos de aprendizaje automático suelen superar a los enfoques lineales tradicionales en tareas de clasificación de incumplimiento, pero esa ganancia viene acompañada de menor transparencia, lo que resulta problemático en dominios regulados como el financiero (Bussmann et al., 2021; Suhadolnik et al., 2023). En este contexto, la contribución de Chen et al. (2024) es especialmente relevante porque desplaza la discusión desde la exactitud predictiva hacia la estabilidad de las explicaciones, una propiedad crítica cuando los modelos sirven de apoyo a decisiones que deben ser justificables ante clientes, auditores y reguladores.

En finanzas, la discusión sobre la "caja negra no es únicamente metodológica, sino también institucional. La creciente adopción de modelos complejos en *credit scoring* convive con exigencias regulatorias que demandan trazabilidad, motivación de decisiones y capacidad de auditoría, especialmente cuando una solicitud de crédito es rechazada. Desde esta perspectiva, la interpretabilidad puede entenderse como el grado en que un ser humano comprende la causa de una decisión del modelo, definición que conecta la literatura técnica con la necesidad práctica de comunicar razones comprensibles y defendibles (Miller, 2019). En otras palabras, en riesgo crediticio no basta con acertar; también es necesario justificar por qué se asignó un nivel de riesgo determinado.

Los modelos no lineales y los métodos de ensamble pueden capturar interacciones complejas, heterogeneidad poblacional y relaciones de umbral que no quedan bien representadas en modelos lineales simples. Sin embargo, su estructura interna es difícil de traducir en reglas claras para justificar decisiones individuales. En riesgo crediticio esto limita la auditabilidad, dificulta la comunica-

ción de razones de rechazo y aumenta el costo de gobernanza del modelo (Bussmann et al., 2021; Molnar, 2019). Por ello, la literatura reciente ha consolidado el uso de métodos de interpretabilidad post-hoc que permiten mantener la potencia predictiva del modelo sin renunciar por completo a la explicación de sus decisiones (Chen et al., 2024). A nivel más amplio, la literatura XAI ha dejado de tratar la explicabilidad como una aspiración ética abstracta y la ha reposicionado como una condición para depuración, validación y control de sesgos en sistemas de alto impacto (Arrieta et al., 2020). En el ámbito financiero, Sanmartín González (2023) enfatiza que estas herramientas también cumplen una función de coherencia económica: ayudan a verificar que variables como edad, ingresos, historial crediticio o ahorro estén operando bajo una lógica financiera razonable y no como simples correlatos espurios.

Esta tensión remite al *trade-off* entre complejidad y transparencia. Los modelos ante-hoc, como regresiones o árboles simples, ofrecen una lectura más directa de sus coeficientes y reglas, pero a menudo sacrifican capacidad predictiva frente a métodos más flexibles. Los modelos post-hoc, en cambio, preservan el rendimiento predictivo de algoritmos complejos a costa de depender de una segunda capa explicativa. La literatura coincide en que este compromiso se vuelve particularmente delicado cuando los datos presentan desbalance severo, porque la inestabilidad del modelo base puede trasladarse a la inestabilidad de la explicación (Chen et al., 2024; Miller, 2019).

El desbalance de clases es inherente a los portafolios crediticios porque los eventos de incumplimiento suelen representar una fracción pequeña del total de observaciones. Chen et al. (2024) documentan que en ciertos portafolios hipotecarios la tasa de incumplimiento puede ser inferior al 1 %, mientras que en otros productos se ubica alrededor del 5 %. Esta asimetría induce a los clasificadores a favorecer la clase mayoritaria y puede deteriorar la capacidad de identificar clientes riesgosos, aun cuando la exactitud global aparente ser elevada. La literatura sobre técnicas de balanceo ha mostrado además que la respuesta del modelo depende de la razón de desbalance, del tamaño muestral y del clasificador utilizado, sin que exista una técnica universalmente superior (Alam et al., 2020; Namvar et al., 2018; Zhao et al., 2024).

Desde la perspectiva aplicada, el problema no se agota en el sesgo predictivo. Corregir la distribución de clases modifica el conjunto de entrenamiento y, por tanto, reconfigura la estructura que aprenden los algoritmos. Si las explicaciones locales dependen de esa estructura, entonces el balanceo puede alterar tanto el orden de importancia de las variables como la magnitud de sus atribuciones. Ese punto es central en esta investigación: el desbalance no solo afecta la capacidad de detectar incumplimiento, sino también la confiabilidad de las razones que el sistema ofrece para justificar cada decisión. Esta preocupación enlaza de forma directa con la gobernanza del modelo, la mitigación de sesgos y la necesidad de distinguir señales económicamente plausibles de patrones espurios u *overfitting* (Arrieta et al., 2020; Chen et al., 2024; Sanmartín González, 2023).

3. Datos

El análisis empírico se basa en dos conjuntos de datos de riesgo crediticio. El primero es *German Credit Risk*, utilizado como base principal por su presencia recurrente en estudios de clasificación crediticia y por permitir una comparación controlada con la literatura previa. La base contiene observaciones individuales de solicitantes de crédito, variables financieras y personales, y una variable binaria de resultado que distingue entre clientes con y sin incumplimiento. Esta estructura es adecuada para evaluar simultáneamente desempeño predictivo y es-

tabilidad interpretativa, dado que el evento de interés suele ser minoritario y la explicación de decisiones individuales resulta relevante para auditoría y gobernanza.

El segundo conjunto es *Home Equity* (HMEQ), incorporado como análisis de robustez externa. En HMEQ la variable objetivo está definida en la columna `BAD`, donde 1 representa incumplimiento y 0 representa pago. Para preservar comparabilidad metodológica, las variables numéricas se imputan mediante la mediana y las variables cualitativas con valores faltantes se codifican con la categoría *Unknown*. La incorporación de HMEQ permite evaluar si los patrones observados en German Credit se mantienen al cambiar la fuente de datos y, por tanto, si las conclusiones son menos dependientes de una única cartera.

La elección conjunta de German Credit y HMEQ responde a un criterio de identificación empírica y robustez. En ambos casos se construyen escenarios con tamaño muestral controlado, niveles de prevalencia definidos y la misma lógica de partición entrenamiento-prueba. Así, las diferencias en estabilidad explicativa se atribuyen al grado de desbalance, al mecanismo de remuestreo y al clasificador utilizado, no a cambios arbitrarios en el flujo experimental.

4. Metodología

4.1. Diseño general y componentes del estudio

Esta investigación extiende el diseño de Chen et al. (2024) al introducir explícitamente técnicas de balanceo en distintos niveles de desbalance controlado. El objetivo no es únicamente estudiar si la rareza del incumplimiento deteriora la estabilidad de las explicaciones, sino también determinar si esa degradación cambia cuando el conjunto de entrenamiento se deja sin balanceo o se interviene mediante remuestreo aleatorio. El diseño se organiza en torno a cinco componentes: dos bases de datos (German Credit y HMEQ), dos clasificadores de caja negra (XGBoost y Random Forest), dos explicadores locales (SHAP y LIME), tres escenarios de entrenamiento (Base, RUS y ROS) y dos métricas de estabilidad explicativa (SRA y CV).

4.2. Modelos de Machine Learning para la Gestión de Riesgo Crediticio

La elección de modelos responde a criterios de capacidad predictiva, uso frecuente en *credit scoring* y compatibilidad con herramientas de interpretabilidad post-hoc. El diseño original contemplaba XGBoost como clasificador base para aislar el efecto del desbalance y del balanceo sobre las explicaciones. Sin embargo, para dotar de mayor robustez a los hallazgos y confirmar que la degradación observada no es un artefacto exclusivo de ese algoritmo, se incorpora un segundo clasificador basado en ensambles: *Random Forest Classifier*. Ambos modelos se evalúan de manera simultánea en cada repetición y bajo idénticas condiciones de preprocesamiento, semillas aleatorias, escenarios de balanceo y técnicas de interpretabilidad.

XGBoost construye una predicción aditiva mediante un conjunto de árboles de decisión. Para una observación i, la salida del modelo se expresa como

$$\hat{y}_i = \sum_{k=1}^{K} f_k(\mathbf{x}_i), \qquad f_k \in \mathcal{F},$$

donde $\mathcal{F}$ denota el espacio de funciones inducido por árboles CART. El ajuste minimiza una función objetivo compuesta por pérdida y regularización,

$$\mathcal{L}(\phi) = \sum_i l(\hat{y}_i, y_i) + \sum_k \Omega(f_k),$$

$$\Omega(f) = \gamma T + \frac{1}{2}\lambda \|w\|^2.$$

Random Forest, por su parte, combina múltiples árboles entrenados sobre muestras

bootstrap y subconjuntos aleatorios de variables. Esta arquitectura reduce varianza y sirve como contraste natural frente al esquema de boosting de XGBoost. Si los resultados se mantienen en ambos clasificadores, la evidencia sobre el efecto interpretativo del balanceo es más robusta.

4.3. Técnicas para el Tratamiento de Datos Desbalanceados

Para cada nivel de desbalance se comparan tres escenarios de entrenamiento. El escenario Base conserva la distribución original inducida por el muestreo experimental; *Random Under-Sampling* (RUS) reduce aleatoriamente la clase mayoritaria; y *Random Over-Sampling* (ROS) replica aleatoriamente observaciones de la clase minoritaria. Las técnicas sintéticas e híbridas, como SMOTE, ADASYN o SMOTE-ENN, se mantienen fuera del diseño principal para no mezclar el efecto de redistribución simple con el efecto adicional de generar observaciones artificiales.

La distinción entre RUS y ROS es sustantiva. RUS corrige el desbalance al costo potencial de eliminar información de la clase mayoritaria, mientras que ROS preserva toda la muestra original pero refuerza la presencia de la minoritaria mediante duplicación. En términos interpretativos, ambas estrategias alteran el entorno estadístico sobre el que se ajusta el modelo y pueden modificar tanto el ranking de variables relevantes como la magnitud de sus atribuciones.

4.4. Métodos de explicabilidad y estabilidad

El análisis se concentra en explicaciones locales generadas por SHAP y LIME. LIME aproxima localmente el comportamiento del modelo complejo mediante un sustituto interpretable ajustado sobre perturbaciones de una observación objetivo. SHAP asigna contribuciones por variable a partir de valores de Shapley y ofrece una descomposición aditiva con fundamentos axiomáticos más fuertes. La comparación entre ambos permite evaluar si la sensibilidad al balanceo depende del mecanismo de explicación.

La estabilidad se mide con dos métricas complementarias. Primero, el *Sequential Rank Agreement* (SRA) evalúa la concordancia entre listas ordenadas de importancia a profundidad fija $d = 1$ (Ekstrøm et al., 2015). Segundo, el coeficiente de variación (CV) resume la dispersión relativa de las magnitudes atribuidas por SHAP o LIME entre repeticiones. Valores menores de SRA y CV indican mayor estabilidad interpretativa.

4.5. Diseño experimental

El estudio adopta un diseño factorial con medidas repetidas. Para cada base de datos se define una malla de niveles de desbalance $\mathcal{U}$ compuesta por 1 %, 2.5 %, 5 % y saltos de cinco puntos porcentuales entre 10 % y 50 %. Para cada nivel se comparan tres estrategias de entrenamiento: Base, RUS y ROS. Cada combinación se evalúa con XGBoost y Random Forest, y las explicaciones se generan con SHAP y LIME. El experimento se repite $B = 10$ veces con semillas controladas para estimar variabilidad sin sacrificar reproducibilidad. En German Credit se mantiene un tamaño muestral fijo de $Z = 420$ observaciones por escenario; en HMEQ se replica el mismo marco de validación con la malla completa de desbalance y la misma lógica de entrenamiento, explicación y agregación de métricas.

Para garantizar el rigor empírico y aislar el verdadero efecto que el remuestreo de clases ocasiona, se fija el tamaño de la muestra en $Z = 420$ observaciones durante todas las inducciones sintéticas de German Credit. Esto permite excluir el efecto de pérdida o adición de poder estadístico originado por la mera reducción volumétrica. La estructura

constante del conjunto inducido se resume en la Tabla 1: en escenarios de extremo desbalance como 1 %, la muestra contiene apenas 4 casos de incumplimiento frente a 416 casos de pago; al 10 %, la relación es de 42 frente a 378; y el recorrido escala progresivamente hasta alcanzar el balance perfecto de 50 % con 210 observaciones para cada clase. Esta granularidad controlada permite medir la degradación interpretativa a lo largo de un espectro continuo de severidad.

Tabla 1: Composición inducida de la muestra fija de $Z = 420$ observaciones en German Credit.

Incumplimiento (%)	Casos malos	Casos buenos	Total
1.0	4	416	420
2.5	11	409	420
5.0	21	399	420
10.0	42	378	420
15.0	63	357	420
20.0	84	336	420
25.0	105	315	420
30.0	126	294	420
35.0	147	273	420
40.0	168	252	420
45.0	189	231	420
50.0	210	210	420

4.6. Diagrama de flujo experimental

El siguiente diagrama resume visualmente el flujo completo del experimento, desde la selección de bases de datos hasta las pruebas estadísticas finales. La estructura conserva la lógica del diseño original, pero incorpora la extensión de robustez con HMEQ y la comparación simultánea entre XGBoost y Random Forest.

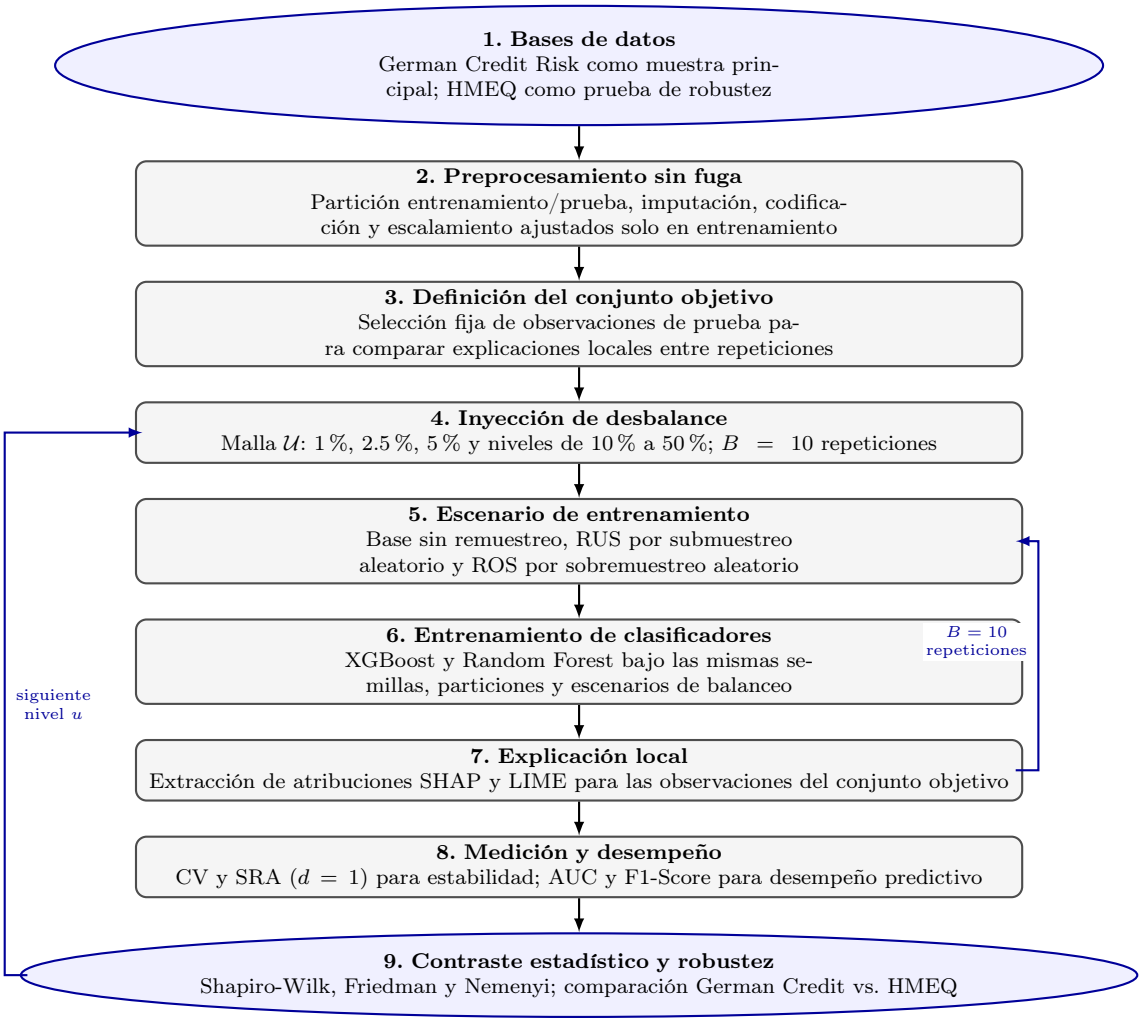


Figura 1: Diagrama de flujo experimental para evaluar balanceo, desempeño predictivo y estabilidad de explicaciones locales.

4.7. Partición y control de fuga

Cada escenario se divide mediante partición estratificada en entrenamiento y prueba. Todas las transformaciones de preprocesamiento se ajustan únicamente sobre el conjunto de entrenamiento y luego se aplican al conjunto de prueba correspondiente. El balanceo, cuando aplica, se ejecuta exclusivamente sobre entrenamiento para evitar *data leakage*. En HMEQ, la imputación por mediana para variables numéricas y la categoría *Unknown* para variables cualitativas faltantes se integran dentro del mismo flujo, preservando la separación entrenamiento-prueba.

Para erradicar cualquier riesgo de aprendizaje anticipado espurio, el diseño implementa una estandarización rigurosa de las variables continuas. Los parámetros de escalado, como la media y la varianza, se ajustan estadísticamente de forma exclusiva sobre el conjunto de entrenamiento aislado. Posteriormente, estas distribuciones maestras se proyectan sobre el conjunto de prueba correspondiente. De esta manera, el modelo nunca tiene acceso implícito a la topología estadística de las observaciones futuras.

4.8. Control de semillas y reproducibilidad

La reproducibilidad se garantiza mediante una semilla base global y una semilla específica por repetición,

$$\texttt{semilla}_r = \texttt{SEMILLA} + r, \qquad r = 1, \ldots, B.$$

Esta semilla se propaga a las particiones, al remuestreo, a XGBoost, a Random Forest y a LIME. TreeSHAP es determinista condicional al modelo entrenado; por tanto, una vez fijados datos, particiones y semillas del clasificador, sus atribuciones quedan determinadas. Este control permite atribuir las diferencias entre escenarios al diseño experimental y no a fluctuaciones accidentales del generador aleatorio.

4.9. Pruebas estadísticas

Para complementar la lectura visual de las curvas, se incorporan pruebas estadísticas sobre las métricas de estabilidad. Primero se aplica Shapiro-Wilk para evaluar normalidad en las distribuciones de CV y SRA. Cuando se rechaza normalidad, se descarta ANOVA de medidas repetidas y se utiliza la prueba no paramétrica de Friedman para contrastar diferencias entre Base, RUS y ROS. Si Friedman rechaza la hipótesis nula, se recurre a contrastes post-hoc de Nemenyi para identificar los pares de escenarios que explican las diferencias.

5. Resultados

Los resultados se presentan separando la base principal (German Credit) y el análisis de robustez (HMEQ). En todas las figuras, las líneas continuas representan XGBoost y las líneas punteadas representan Random Forest. Esta convención permite comparar simultáneamente el efecto del balanceo, el método de explicación y la arquitectura predictiva.

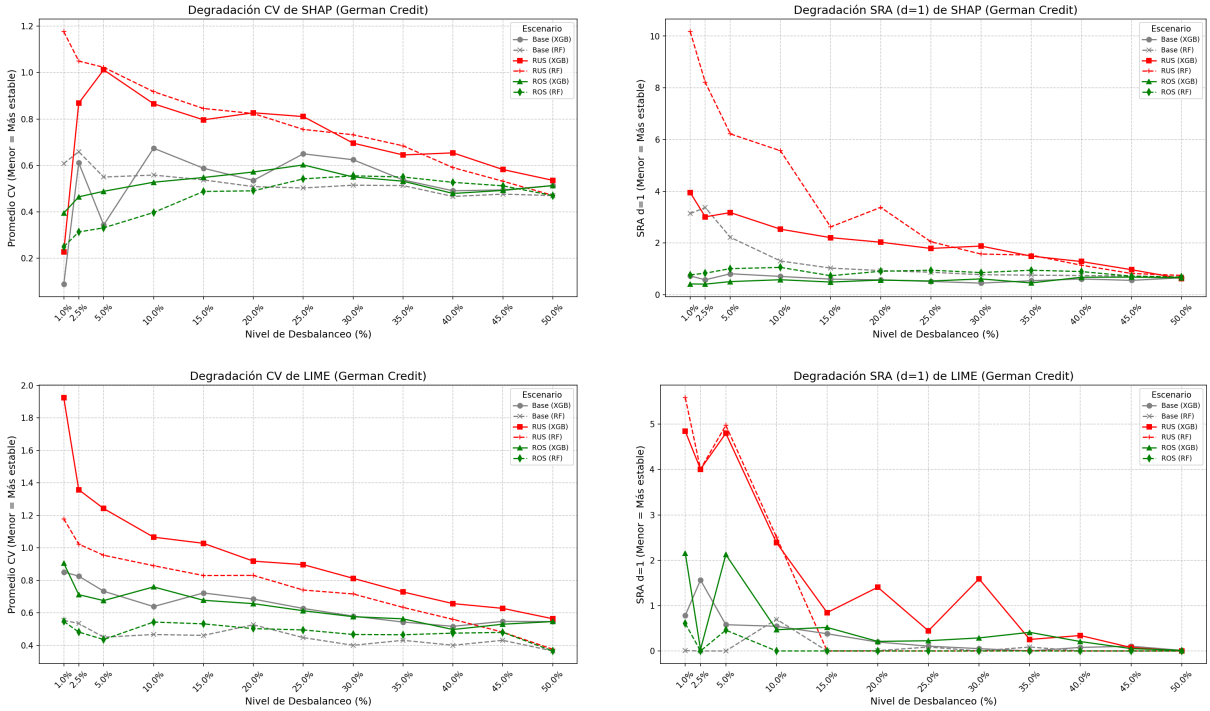


Figura 2: Métricas de estabilidad explicativa en German Credit. Las líneas continuas corresponden a XGBoost y las líneas punteadas a Random Forest.

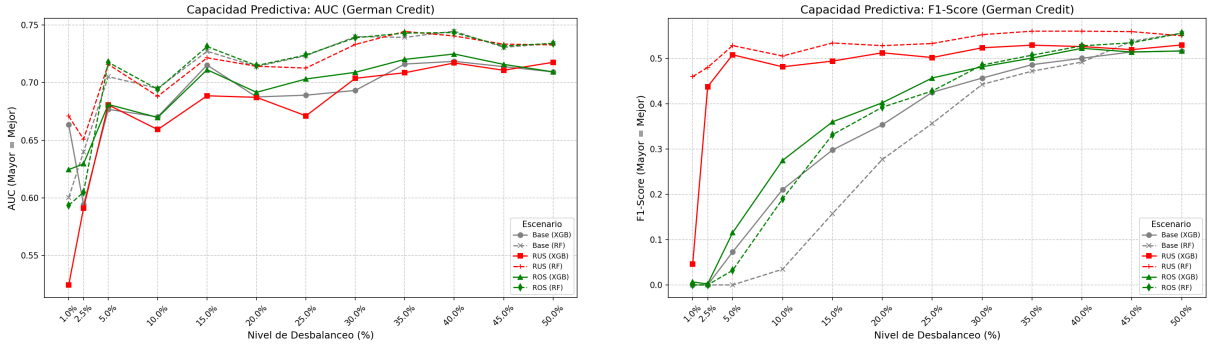


Figura 3: Desempeño predictivo en German Credit medido mediante AUC y F1-Score. Las líneas continuas corresponden a XGBoost y las líneas punteadas a Random Forest.

5.1. Resultados en German Credit

La Figura 2 muestra que la estabilidad explicativa no depende únicamente de la proporción de la clase minoritaria, sino también de la intervención metodológica aplicada al entrenamiento. En SHAP y LIME, RUS concentra la mayor degradación interpretativa, tanto en la variabilidad de las atribuciones (CV) como en la discrepancia de rankings (SRA). ROS se mantiene más cerca del escenario Base y, en varios niveles de desbalance, preserva trayectorias más suaves. La incorporación de Random Forest confirma que el patrón no es exclusivo de XGBoost: aunque las magnitudes cambian entre clasificadores, la jerarquía cualitativa entre Base, RUS y ROS se mantiene.

La Figura 3 complementa esta lectura. Las métricas AUC y F1-Score permiten verificar que las decisiones de balanceo no deben evaluarse solo por desempeño predictivo. En algunos tramos, una estrategia puede

preservar o mejorar el F1-Score y, al mismo tiempo, introducir mayor volatilidad en las explicaciones. Esta divergencia refuerza la necesidad de validar los modelos de riesgo crediticio con criterios predictivos e interpretativos.

5.2. Análisis estadístico adicional en German Credit

Para dotar de mayor rigor a las diferencias visuales observadas en German Credit, se verifica primero el supuesto de normalidad mediante Shapiro-Wilk sobre las métricas de estabilidad. Al rechazarse la normalidad en las distribuciones evaluadas, se justifica el uso de la prueba no paramétrica de Friedman como alternativa a ANOVA de medidas repetidas. Friedman contrasta si existen diferencias sistemáticas entre Base, RUS y ROS a través de la malla de desbalance, mientras que los contrastes post-hoc de Nemenyi permiten identificar los pares de escenarios responsables de las diferencias cuando la hipótesis nula es rechazada.

La evidencia estadística es coherente con la lectura gráfica: el mecanismo de remuestreo altera de forma significativa la estabilidad explicativa. En particular, RUS aparece como la intervención más disruptiva, mientras que ROS opera como una alternativa menos costosa desde el punto de vista interpretativo. En consecuencia, el análisis estadístico respalda la idea central del estudio: las técnicas de balanceo no son neutrales para la explicabilidad y deben someterse a validación explícita.

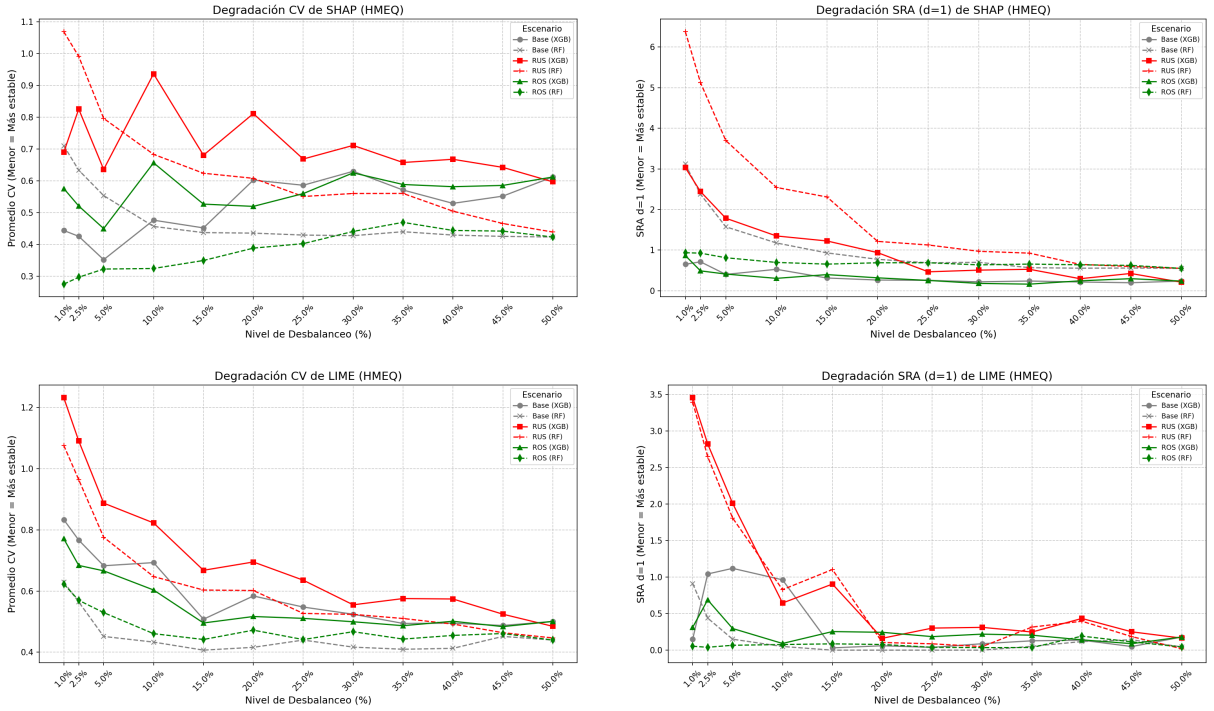


Figura 4: Métricas de estabilidad explicativa en HMEQ. Las líneas continuas corresponden a XGBoost y las líneas punteadas a Random Forest.

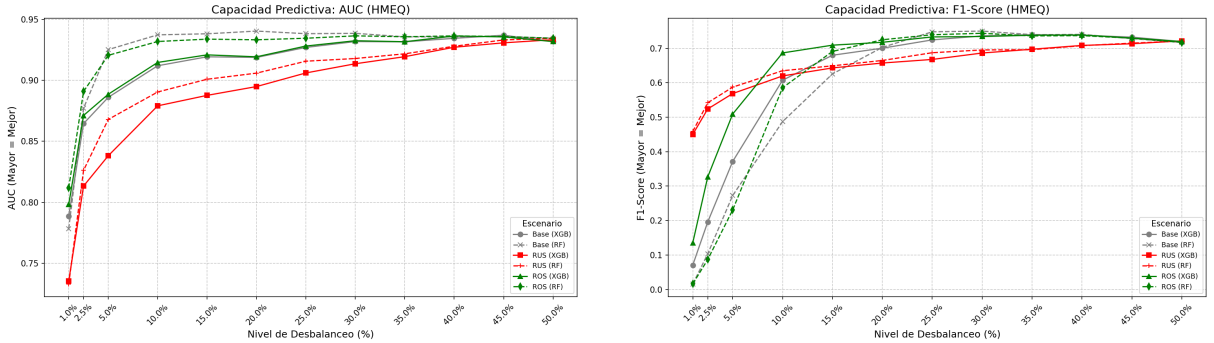


Figura 5: Desempeño predictivo en HMEQ medido mediante AUC y F1-Score. Las líneas continuas corresponden a XGBoost y las líneas punteadas a Random Forest.

5.3. Análisis de robustez en HMEQ

Para confirmar que los hallazgos no son un artefacto exclusivo de German Credit, se replica el marco de validación en HMEQ. La Figura 4 muestra que el patrón general se mantiene: RUS introduce la mayor inestabilidad en las explicaciones, mientras que ROS permanece más cercano al escenario Base. La consistencia del resultado en una base distinta y con dos clasificadores refuerza la robustez externa del argumento.

En el bucle principal de evaluación de HMEQ, cada nivel de desbalance de la malla se entrena con XGBoost y Random Forest bajo los escenarios Base, RUS y ROS. A cada modelo se le extraen explicaciones SHAP y LIME, y se calculan CV y SRA con la misma definición utilizada en German Credit. La Figura 5 muestra que el desempeño predictivo también varía con el mecanismo de remuestreo, pero no siempre en la misma dirección que la estabilidad interpretativa.

Por ello, la robustez predictiva no sustituye la evaluación de estabilidad explicativa.

5.4. Pruebas estadísticas finales en HMEQ

Las pruebas de Shapiro-Wilk aplicadas sobre los tres escenarios para CV de SHAP y SRA ($d = 1$) de SHAP evidencian incumplimiento del supuesto de normalidad. Al violarse este supuesto, se descarta ANOVA de medidas repetidas y se procede con la prueba no paramétrica de Friedman. Ambas pruebas de Friedman arrojan p-values inferiores a 0,001, por debajo del nivel de significancia $\alpha = 0{,}05$.

Este resultado confirma que el nivel de desbalance y la técnica de remuestreo afectan de forma estadísticamente significativa tanto la magnitud de las atribuciones SHAP como la consistencia del ordenamiento de variables. La replicación en HMEQ valida externamente los hallazgos del experimento principal y refuerza la conclusión de que el balanceo modifica la capa interpretativa del modelo.

6. Discusión

La comparación conjunta de German Credit y HMEQ permite extraer cuatro implicaciones. Primero, el balanceo aleatorio sí altera la consistencia explicativa, por lo que no debe evaluarse únicamente a partir de métricas predictivas. Segundo, RUS emerge como la técnica más costosa en términos interpretativos: reduce el volumen efectivo de información de la clase mayoritaria y amplifica la variabilidad de los mecanismos locales de explicación. Tercero, ROS se comporta como una alternativa menos disruptiva, ya que preserva trayectorias próximas al escenario Base sin introducir una degradación tan persistente en SRA y CV. Cuarto, la comparación entre XGBoost y Random Forest muestra que el resultado no depende de una única arquitectura predictiva.

Un hallazgo crucial que emerge de las curvas de degradación es la marcada diferencia de robustez entre los métodos explicativos frente a las intervenciones de balanceo. Independientemente del nivel de desbalance, LIME manifiesta mayor volatilidad al reconstruir el vecindario local de las observaciones objetivo. Su naturaleza matemática, basada en una aproximación local mediante regresión Ridge sobre muestras perturbadas, resulta especialmente vulnerable a los vacíos de información generados por el submuestreo aleatorio (RUS) y a los cambios de densidad inducidos por el remuestreo. Esta inestabilidad se traduce en dispersiones elevadas en el ordenamiento de variables (SRA) y en la magnitud de las atribuciones (CV).

Por el contrario, SHAP experimenta una menor perturbación relativa, comportamiento consistente con su fundamentación en valores de Shapley y con una descomposición aditiva menos dependiente de una muestra local sintética. Mientras LIME puede fragmentar bruscamente la topología local de decisión del algoritmo bajo escasez de datos, SHAP preserva un nivel de cohesión analítica superior. Esta diferencia no implica que SHAP sea inmune al desbalance, sino que su deterioro empírico es menos severo y más compatible con una validación interpretativa auditable.

Estos hallazgos son coherentes con la motivación planteada en la literatura reciente: el desbalance afecta la inferencia del modelo, pero la forma específica de corregirlo también reconfigura la capa interpretativa (Chen et al., 2024). La contribución de esta investigación consiste en mostrar que la estabilidad de las explicaciones cambia de manera no trivial cuando se modifica el mecanismo de balanceo, incluso al replicar el análisis en dos bases de datos y dos clasificadores. Por ello, el criterio de selección entre Base, RUS y ROS no debería descansar solo en exactitud, *recall*, AUC o F1-Score, sino también en la estabilidad del ranking explicativo y de la intensidad de las atribu-

ciones.

7. Conclusión e investigaciones futuras

La evidencia obtenida permite concluir que la estabilidad explicativa en riesgo crediticio depende tanto del grado de desbalance como de la estrategia utilizada para corregirlo. El resultado más robusto del estudio es que RUS deteriora de forma consistente la estabilidad de las explicaciones locales, elevando simultáneamente la variabilidad de las atribuciones (CV) y la discrepancia entre rankings de importancia (SRA). En cambio, ROS muestra un comportamiento considerablemente más estable y cercano al escenario Base, lo que lo convierte en una opción menos costosa desde la perspectiva interpretativa.

La solidez de estas conclusiones se encuentra respaldada por un análisis de robustez cruzado. Los efectos perjudiciales de RUS sobre la estabilidad explicativa y la mayor regularidad relativa de SHAP frente a LIME se mantienen no solo al cambiar la arquitectura del modelo de XGBoost a Random Forest, sino también al replicar el diseño experimental completo en HMEQ. Además, las pruebas no paramétricas de Friedman y los contrastes post-hoc de Nemenyi respaldan que las diferencias observadas entre escenarios de balanceo son estadísticamente relevantes.

La inestabilidad metodológica evidenciada en ciertas herramientas de explicabilidad tiene implicaciones regulatorias relevantes. En riesgo crediticio, utilizar una herramienta como LIME bajo esquemas de escasez y desbalance extremo representa un alto riesgo fiduciario si sus explicaciones locales cambian de manera sustantiva ante perturbaciones mínimas de los datos de entrenamiento. En tales condiciones, el modelo puede carecer de consistencia local suficiente para justificar decisiones individuales ante auditorías internas, clientes o entes reguladores.

Por ello, se concluye que el uso de metodologías de remuestreo subóptimas como RUS debe evitarse cuando el objetivo central es preservar la interpretabilidad. Como recomendación técnica y regulatoria, la presente investigación destaca que la combinación de *Random Over-Sampling* (ROS) junto con SHAP constituye la ruta mitigante idónea dentro del diseño evaluado. Esta dupla permite mantener métricas de consistencia SRA y CV más próximas a las líneas base, asegurando explicaciones comparativamente más confiables y auditables aun cuando el modelo opere en entornos de extremo desequilibrio natural en el mercado crediticio.

A partir de estos hallazgos, la recomendación principal es que las técnicas de balanceo no se seleccionen solo por su impacto sobre precisión predictiva, sino también por su efecto sobre la estabilidad interpretativa. Incorporar métricas como SRA y CV al proceso de validación permite transformar la interpretabilidad en un criterio auditable de control de calidad y no solo en una visualización atractiva. No obstante, las conclusiones deben leerse dentro de las limitaciones del estudio: se evalúan dos bases de datos, dos clasificadores, una malla acotada de desbalance y un número finito de repeticiones.

Como líneas futuras, conviene extender el análisis a métodos sintéticos e híbridos de balanceo, como SMOTE, ADASYN o SMOTE-ENN, y a técnicas de interpretabilidad diferentes, como explicaciones contrafactuales. También sería valioso ampliar la validación a carteras institucionales y bases de datos más grandes para determinar en qué medida la superioridad predictiva de los modelos de *machine learning* compensa las fluctuaciones en su interpretabilidad.

Acknowledgments

No acknowledgments are included in this anonymous version for blind review.

Declaration of Interest

Los autores no informan de conflictos de interés. Solo los autores son responsables del contenido y la redacción del artículo.

Referencias

Alam, T. M., Shaukat, K., Hameed, I. A., Luo, S., Sarwar, M. U., Shabbir, S., Li, J., & Khushi, M. (2020). An Investigation of Credit Card Default Prediction in the Imbalanced Datasets. *IEEE Access*, 8, 201173-201198. https://doi.org/10.1109/ACCESS.2020.3033784

Alarab, I., & Prakoonwit, S. (2022). Effect of data resampling on feature importance in imbalanced blockchain data: Comparison studies of resampling techniques. *Data Science and Management*, 5(2), 66-76. https://doi.org/10.1016/j.dsm.2022.04.003

Araujo, D., Bruno, G., Marcucci, J., Schmidt, R., & Tissot, B. (2023). Machine learning applications in central banking. *Journal of AI, Robotics & Workplace Automation*, 2(3), 271. https://doi.org/10.69554/LSSN4651

Arrieta, A. B., Díaz-Rodríguez, N., Del Ser, J., Bennetot, A., Tabik, S., Barbado, A., *et al.* (2020). Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI. *Information Fusion*, 58, 82-115. https://doi.org/10.1016/j.inffus.2019.12.012

Bussmann, N., Giudici, P., Marinelli, D., & Papenbrock, J. (2021). Explainable Machine Learning in Credit Risk Management. *Computational Economics*, 57(1), 203-216. https://doi.org/10.1007/s10614-020-10042-0

Chen, Y., Calabrese, R., & Martin-Barragan, B. (2024). Interpretable machine learning for imbalanced credit scoring datasets. *European Journal of Operational Research*, 312(1), 357-372. https://doi.org/10.1016/j.ejor.2023.06.036

Ekstrøm, C. T., Gerds, T. A., Jensen, A. K., & Brink-Jensen, K. (2015). *Sequential rank agreement methods for comparison of ranked lists.* arXiv. https://doi.org/10.48550/arXiv.1508.06803

Kaggle UCI ML Repository. *German Credit Risk.* Kaggle. https://www.kaggle.com/datasets/uciml/german-credit

Melchor Pérez, E., Ramírez Guzmán, M. E., Hernández Jiménez, A., & Santiago Alvarado, A. (2024). Predicción del riesgo crediticio a microfinanciera usando aprendizaje computacional. *Revista Mexicana de Economía y Finanzas*, 19(4), 1-16. https://doi.org/10.21919/remef.v19i4.868

Miller, T. (2019). Explanation in artificial intelligence: Insights from the social sciences. *Artificial Intelligence*, 267, 1-38. https://doi.org/10.1016/j.artint.2018.07.007

Molnar, C. (2019). *Interpretable machine learning. A Guide for Making Black Box Models Explainable*. https://christophm.github.io/interpretable-ml-book/

Namvar, A., Siami, M., Rabhi, F., & Naderpour, M. (2018). Credit risk prediction in an imbalanced social lending environment. *arXiv*. https://doi.org/10.48550/arXiv.1805.00801

Sanmartín González, M. (2023). *Análisis de interpretabilidad de modelos de Machine Learning aplicado a la gestión de riesgos financieros*. Universidad Pontificia Comillas. https://repositorio.comillas.edu/rest/bitstreams/625544/retrieve

Suhadolnik, N., Ueyama, J., & Da Silva, S. (2023). Machine Learning for Enhanced Credit Risk Assessment: An Empirical Approach. *Journal of Risk and Financial Management*, 16(12), 496. https://doi.org/10.3390/jrfm16120496

Welvaars, K., Oosterhoff, J. H. F., van den Bekerom, M. P. J., Doornberg, J. N., van Haarst, E. P., & OLVG Urology Consortium, and the M. L. C. (2023). Implications of resampling data to address the class imbalance problem (IRCIP). *JAMIA Open*, 6(2), ooad033. https://doi.org/10.1093/jamiaopen/ooad033

Zhao, Z., Cui, T., Ding, S., Li, J., & Bellotti, A. G. (2024). Resampling Techniques Study on Class Imbalance Problem in Credit Risk Prediction. *Mathematics*, 12(5), 701. https://doi.org/10.3390/math12050701