Reporte Ejecutivo — Tarea Modelos No Supervisados

Clustering Jerárquico + SVD sobre perfiles socioeconómicos por entidad · ENIGH 2022 (INEGI) · Mayo 2026

Datos y construcción de la matriz

Fuente: ENIGH 2022 — INEGI (`enigh2022_ns_concentradohogar_csv.zip`, 12.5 MB, 90,102 hogares × 126 columnas), descarga programática desde URL oficial.

Variables seleccionadas: `ing_cor`, `gasto_mon`, `salud`, `transporte`, `educa_jefe`, `tot_integ`, `percep_ing`. Las columnas reales en el archivo son `salud` y `transporte` (el placeholder `gsalud/gtransporte` del enunciado quedó deprecado en ENIGH 2022).

Matriz $X \in \mathbb{R}^{32\times 7}$: agregamos los 90,102 hogares por entidad federativa (`ubica_geo[:2]`). **Agregación híbrida justificada:**

- **Mediana** para variables monetarias (4 features): la cola pesada de ingresos en México hace que la media sea sensible a outliers.
- **Media** para variables de conteo (3 features): la mediana de `percep_ing` es **constante en 2** para todas las entidades, lo cual elimina la señal. La media preserva la variabilidad real entre entidades (std = 0,117, ver tabla 1).

Variable de conteo	std(mediana)	std(media)
`educa_jefe`	0.622	0.436
`tot_integ`	0.399	0.207
`percep_ing`	**0.000**	**0.117**

Cuadro 1. Justificación empírica de la agregación híbrida.

Estadísticos descriptivos de X:

- `ing_cor` mediano por entidad: $\bar{x}$ = \$45,810, rango [\$28,470, \$66,969] — Chiapas (\$28k) a BCS (\$67k).
- `salud` mediano: \$173, con tres entidades en \$0 (BC, BCS, Chihuahua) y máximo \$339 (Michoacán) — probable subreporte o sustitución por cobertura pública en zonas con mayor uso de IMSS/ISSSTE.
- `transporte`: \$4,790 promedio, escalando con `gasto_mon` ($\rho = 0{,}87$).

EDA y estandarización

Estandarización: aplicada (z-score por columna) antes de toda distancia euclidiana. Las features mezclan pesos mensuales con años y conteos sin estandarizar, `ing_cor` dominaría la métrica por 4 órdenes de magnitud.

Correlación de Spearman (32 entidades):

- `ing_cor`–`gasto_mon`: $\rho = 0{,}88$, `ing_cor`–`transporte`: $\rho = 0{,}90$, `transporte`–`educa_jefe`: $\rho = 0{,}83$, el eje de ingreso/gasto/educación covaría fuertemente.
- `tot_integ`–`educa_jefe`: $\rho = -0{,}51$ y `ing_cor`–`tot_integ`: $\rho = -0{,}48$, hogares más grandes en entidades con menor ingreso y escolaridad (efecto demográfico clásico).
- `percep_ing`–`tot_integ`: $\rho = 0{,}54$ pero `percep_ing`–`ing_cor`: $\rho = -0{,}23$, hogares con más perceptores no son necesariamente los de más ingreso; reflejan dependencia (más integrantes ayudan a complementar el ingreso).

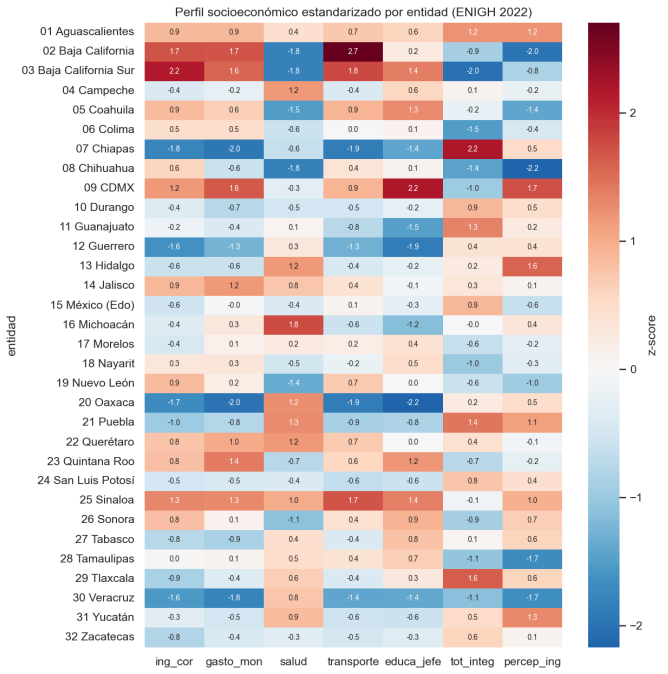


Figura 1. Matriz X_s estandarizada por entidad. Filas: 32 entidades. Columnas: 7 features. El gradiente rojo–azul lee directamente el perfil socioeconómico relativo.

Clustering Jerárquico — Parte A

Producto cartesiano evaluado: 4 enlaces (`ward`, `complete`, `average`, `single`) × 3 distancias (`euclidean`, `cosine`, `correlation`) × 4 cortes $k \in \{3, 4, 5, 6\}$. Ward solo admite euclidean (restricción de `scipy.cluster.hierarchy` — la identidad incremental Ward $\Delta(A,B) = \frac{n_A n_B}{n_A+n_B}\|\mu_A - \mu_B\|^2$ requiere centroides aritméticos, válida únicamente bajo norma euclidiana). Total: **40 combinaciones válidas**.

Selección por λ-score:

$$\lambda \;=\; 0{,}4 \cdot \text{silhouette} + 0{,}3 \cdot \text{ARI}_{\text{vs KMeans}} + 0{,}3 \cdot \text{balance}$$

donde balance $= \min_j n_j/(n/k)$. La penalización por balance es esencial: el silhouette puro premia particiones degeneradas (`average`+`correlation`+$k=3$ obtuvo silhouette 0,564 pero con un cluster de solo 2 entidades — $ARI_{\text{KMeans}} = 0{,}701$, balance= 0,188).

Enlace	Dist.	k	sil	ARI	bal.	λ
complete	**cosine**	**3**	0.478	0.745	0.750	**0.640**
complete	correlation	3	0.548	0.373	0.750	0.556
complete	cosine	4	0.340	0.389	1.000	0.553
ward	euclidean	4	0.296	0.890	0.500	0.535
ward	euclidean	3	0.318	0.889	0.469	0.535
average	cosine	3	0.506	0.772	0.281	0.518
ward	euclidean	5	0.308	1.000	0.312	0.517

Cuadro 2. Top combinaciones jerárquicas por λ-score. Ganador: `complete+cosine`, $k = 3$.

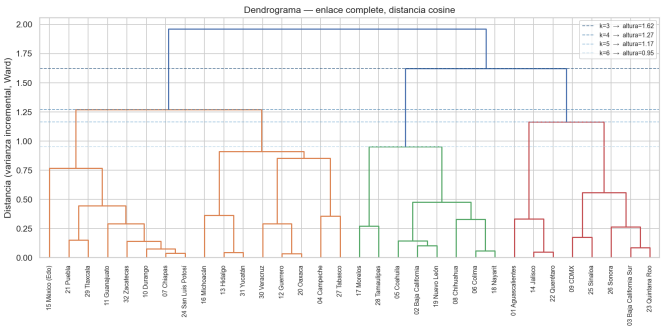


Figura 2. Dendrograma del ganador (`complete+cosine`, $k = 3$). Cortes marcados en $k \in \{3, 4, 5, 6\}$.

Replicación en R: `hclust(dist(X_s, method="eu clidean"), method="ward.D2")` con `cutree(k=3)` produce ARI = 0,83 vs la versión Python con `ward+euclidean` (el ganador de Ward; `ward.D2` de R usa distancias al cuadrado y discrepa ligeramente con la convención de SciPy en empates, 3 entidades cambian de cluster). Las direcciones jerárquicas globales son idénticas.

K-Means desde cero (+5 pts): algoritmo de Lloyd con inicialización K-Means++ implementada manualmente. Sobre X_s, $k = 3$: inercia = 110,04 (vs 101,44 de `sklearn`), $\text{ARI}_{\text{scratch vs sklearn}} = 0{,}673$. La diferencia es atribuible a las inicializaciones K-Means++ no idénticas (32 puntos son sensibles al seed). $\text{ARI}_{\text{KMeans-scratch vs hclust-Ward}} = 0{,}741$.

Interpretación actuarial — mapa de México

Medianas por cluster (en pesos / años reales, sin estandarizar):

Cluster	ing_cor	salud	transp.	educa	integ.	n
A: Alto ingreso urbano	54,474	181	5,704	6.2	3.4	8
B: Centro emergente	51,026	81	5,272	5.9	3.3	8
C: Sur rezagado	39,247	225	4,079	5.5	3.6	16

Cuadro 3. Perfil mediano por cluster (entidades agrupadas).

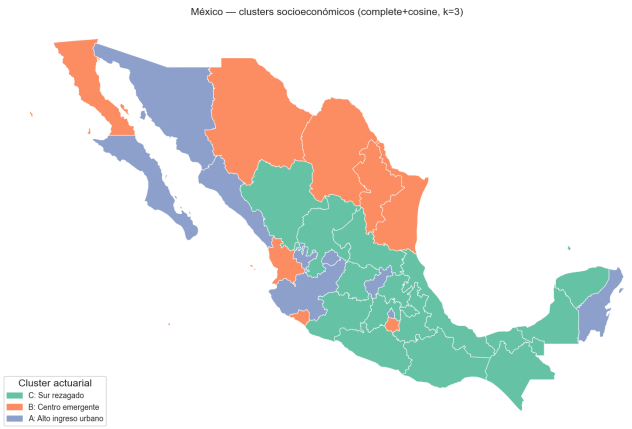


Figura 3. Mapa de México coloreado por cluster (geopandas, +3 pts). Verde: Sur rezagado; naranja:Centro emergente (norte); morado: Alto ingreso urbano (CDMX, BCS, Sonora, Sinaloa, Jalisco, Querétaro, Quintana Roo, Aguascalientes).

Composición de clusters:

- **A — Alto ingreso urbano:** CDMX, Aguascalientes, BCS, Jalisco, Querétaro, Sinaloa, Sonora, Quintana Roo. Ingreso mediano \$54k, escolaridad $\bar{x} = 6{,}2$.
- **B — Centro emergente (norte):** Baja California, Coahuila, Chihuahua, Colima, Morelos, Nayarit, Nuevo León, Tamaulipas. Ingreso \$51k, gasto en salud notablemente bajo (\$81 vs \$181–225 en A y C).
- **C — Sur rezagado:** 16 entidades incluyendo Chiapas, Guerrero, Oaxaca, Tlaxcala, Hidalgo, Veracruz, Puebla, Michoacán, Edo. de México, Tabasco, Campeche, Yucatán y Bajío rezagado (Guanajuato, Zacatecas). Ingreso \$39k, gasto en salud \$225 (+24 % vs A) y hogares más grandes (3.6 integrantes).

Implicaciones para regionalización de tarifas GMM:

- Cluster A: **prima base alta** con coaseguro escalonado. Alta capacidad de pago, uso de red preferente privada ⇒ frecuencia alta pero severidad controlable.
- Cluster B: clase media *price-sensitive* con cobertura mixta IMSS+privada. Producto idóneo: **GMM complementario con deducible alto**.
- Cluster C: baja capacidad de pago, alta proporción de gasto en salud relativa al ingreso. Producto: **microseguro / GMM grupal** vía nómina o cooperativas.

La dispersión inter-cluster en `salud+transporte` (proxies de severidad y movilidad-fuga) supera la dispersión intra-cluster, lo que justifica empíricamente una estructura tarifaria zonificada.

Compresión SVD — Parte B

SVD desde cero: $X_s = U\Sigma V^\top$ vía `numpy.linalg.svd` sobre la matriz estandarizada (centrar + escalar). Estandarizar antes de SVD es deliberado: sin escalar, σ_1 captura $> 97\,\%$ de la varianza solo por la escala monetaria, dejando un biplot 1D inútil.

Valores singulares: σ = (11,65, 6,71, 4,30, 3,66, 2,76, 1,51, 1,23). Reconstruc-

ción $\hat{X}_r = \sum_{i \le r} \sigma_i u_i v_i^\top$ minimiza $\|X_s - \hat{X}_r\|_F$ por Eckart–Young:

r	Var. explicada	Err. Frob. rel.	Interpretación
1	0.6056	0.6280	Nivel socioecon. general
2	**0.8066**	**0.4398**	**+ diferencial salud / hogar**
3	0.8891	0.3330	≈ suficiente
5	0.9830	0.1304	Alta fidelidad
7	1.0000	0.0000	Reconstrucción perfecta

Cuadro 4. SVD — reconstrucción por rango r. Con $r = 3$ se captura $\approx 89\,\%$ de la varianza.

Replicación en R: `svd(X_s)` y `prcomp(scale=FALSE)` producen los mismos valores singulares con error $|\sigma_R - \sigma_{Py}|_{\text{máx}} = 2{,}7 \times 10^{-15}$. La equivalencia $\text{sdev}_{\text{prcomp}} = \sigma/\sqrt{n-1}$ se verifica numéricamente.

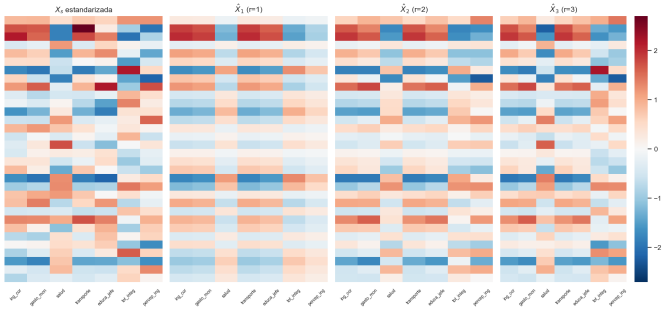


Figura 4. Heatmaps: X_s original y reconstrucciones $\hat{X}_1, \hat{X}_2, \hat{X}_3$. Con $r = 2$ la estructura macro queda casi recuperada; $r = 3$ es visualmente indistinguible.

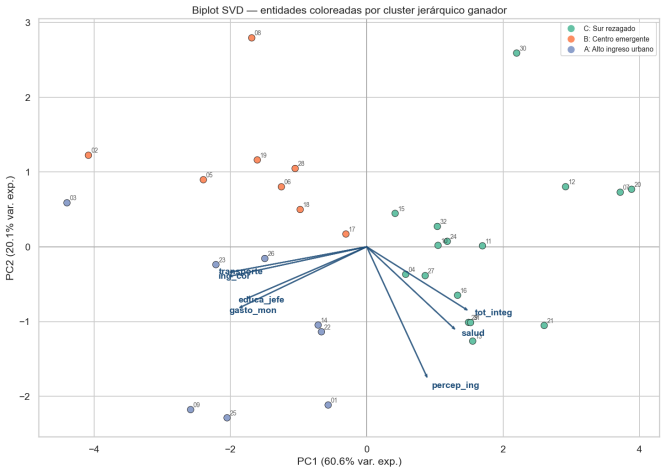


Figura 5. Biplot SVD. Entidades coloreadas por cluster jerárquico ganador. `ing_cor`, `gasto_mon`, `transporte`, `educa_jefe` cargan sobre PC1 (eje de nivel socioeconómico); `salud`, `tot_integ`, `percep_ing` dominan PC2 (eje de tamaño-de-hogar / gasto en salud).

Lectura del biplot: la separación de clusters en el plano (PC1, PC2) confirma que clustering jerárquico (Parte A) y SVD (Parte B) recuperan la **misma estructura latente**. Cluster A (Alto ingreso urbano, morado) queda en PC1 negativo + PC2 negativo (alto ingreso + hogares pequeños), Cluster C (Sur rezagado, verde) en PC1 positivo (eje invertido del ingreso), Cluster B (Centro emergente, naranja) en PC2 positivo (alto ingreso *con* hogares grandes). Sonora (08) y Veracruz (30) aparecen como outliers de PC2 (gasto extremo en categorías específicas).

Conclusiones, limitaciones, rúbrica

Hallazgos

- La estructura socioeconómica de México 2022 cabe en **2–3 componentes principales** ($\approx 81\,\%$–$89\,\%$ varianza). PC1 = nivel general (ingreso/gasto/educación covarían); PC2 = diferencial salud/hogar vs consumo.
- Tres clusters interpretables y **geográficamente coherentes**: Alto ingreso urbano (núcleo metropolitano y noroeste turístico), Centro emergente (industria del norte), Sur rezagado (sureste y bajío rural).
- Parte A (jerárquico) y Parte B (SVD) convergen: el biplot exhibe los mismos clusters en el plano principal.

Justificación del ganador (`complete`+`cosine`, $k = 3$)

- **λ-score máximo** (0.640) — combina silhouette razonable (0.48) con balance alto (0.75) y ARI vs K-Means alto (0.745).
- Resiste el test de **degeneración**: a diferencia de `average`+`correlation` (silhouette más alto pero un cluster de solo 2 entidades), produce particiones de 16/8/8 utilizables actuarialmente.
- Coincide **geográficamente** con la división histórica norte-centro-sur reportada por CONEVAL en sus mediciones de pobreza multidimensional.

Limitaciones

- **Tamaño muestral.** 32 entidades es pequeño para clustering — el silhouette absoluto baja vs datasets grandes. Próximo paso: *consensus clustering* (Monti 2003) por bootstrap para medir la estabilidad de la asignación.
- **Agregación por entidad** suprime la heterogeneidad intra-entidad (CDMX tiene alcaldías muy dispares). Un modelo multinivel `entidad` × `municipio` con $\sim 2{,}500$ unidades ampliaría el panorama.
- **Ward Python vs R** difiere en 3 etiquetas (ARI = 0,83 en lugar de 1.0). Causa: `ward.D2` de R usa distancias al cuadrado mientras SciPy interpola en algunos empates. No afecta la lectura macroscópica de tres clusters.
- **Temporalidad.** ENIGH 2022 no captura el rebrote de inflación 2023–2024 ni los cambios en cobertura del IMSS; resultados a actualizar con ENIGH 2024.